

MLP を使って、求人一覧の給料列を予測する

1. 概要


求人のデータフレームにおいて、給料の列を予測するモデルを、多層パーセプトロン(MLP)を使って作成した。活性化関数などを変えたり、ユニット数を変えたりし、3つの MLP モデルを作成し、それらの精度を MAPE で比較した。

2. データ

2.1 データセット

使用したデータセットは、国際労働機関（ILO）が提供する、ウルグアイの主要な求人ポータルサイトの一つから収集された。28631 行 30 列からなるデータフレームで、特徴量には年齢上限、募集人数、地域、給料などが含まれており、給料を目的変数とする。

給料分布は以下のように、右に歪んだ分布である。



2.2 データ前処理

欠損値に関して、カテゴリカル変数は最頻値で、数値変数には中央値で、補完した。

その後、カテゴリカル変数に対しては one hot encoding を行い、数値変数は正規化を施した。

目的変数の給料である `Sueldo` を対数変換した。

2.3 データ分割

データフレームを、訓練データ 70%、検証データ 15%、テストデータ 15%に分割した。

3. モデル

3.1

1 つ目の MLP モデルは、隠れ層が 2 層あり、それぞれ 64 個と 8 個のユニットから構成されている。活性化関数には、ReLU を用いた。損失関数は `MSELoss` (平均二乗誤差)を採用した。

3.2


2 つ目のモデルは、3 の隠れ層を持っており、それぞれ 128 ユニット、64 ユニット、32 ユニットで構成されている。隠れ層の 1 層と 2 層には、学習の安定化と汎化性能向上のため `Batch normalization`、活性化関数には `LeakyReLU`、過学習抑制のための `Dropout (0.3)` を導入した。隠れ層の 3 層には活性化関数として `LeakyReLU` を適用した。`Batch Normalization` は各層の出力分布を正規化することで学習を安定化させ、収束を速めてくれる。`Dropout` は学習時に一部のユニットを確率的に無効化することで特定の特徴への過度な依存を防ぎ、過学習を抑制してくれる。損失関数には、`SmoothL1Loss` を使った。`SmoothL1Loss` は誤差が小さい領域では二乗誤差 (L2) 的に振る舞い、誤差が大きい領域では絶対誤差 (L1) 的に振る舞うため、外れ値の影響を受けにくいという利点がある。

3.3

3 つ目のモデルは 2 つ目のモデルの層の数を減らしたモデルであり、隠れ層が 2 層で、それぞれ 128 ユニットと 64 ユニットで構成されている。活性化関数には

LeakyReLU を用いた。損失関数は 1 つ目のモデルと同様に MSELoss を採用した。

4. 学習



モデル 1 とモデル 3 はすぐに収束していることがわかり、モデル 2 は 20 エポック当たりで収束していることがわかる。モデル 2 において、一時的に、検証データの損失が訓練データの損失を下回っているが、それは Dropout や Batch Normalization の影響であると考えられる。検証データでは、Dropout は無効になる。Batch Normalization に関して、学習データで正規化用の各バッチで算出された平均と分散が、`running_mean`, `running_variance` として蓄積されて、その値が検証データの正規化の際に使われるため、検証データでは平均と分散がバッチごとに変わる揺れがなくなる。

また、どのモデルも過学習を起こしていないことがわかる。

5. 評価


Model	MAPE(%)
model1	2.59
model2	2.40
model3	2.81

MAPE を使って評価したところ、モデル 2 の MAPE が 2.40 が最も低かった。

6. テストデータ

テストデータをモデル 2 に使って、その予測値と実際の値を比較したグラフが以下の通りである。

テストデータにおけるモデル 2 の MAPE は 2.34%であった。



7. 結論

モデル 2 に、Batch Normalization や Dropout を導入したことで、モデルの精度が向上したと考えられる。Batch Normalization で、各バッチの出力分布を正規化して収束を早め、さらに Dropout で一部のユニットを確率的に無効化して、過学習を抑制することができた。